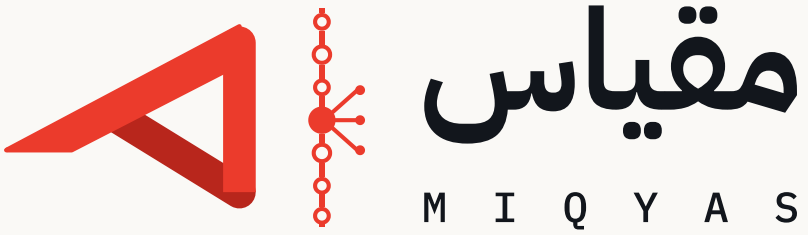
هل يقدر نموذج عربي مفتوح يدير استقبال عيادة على واتساب، من غير إنترنت؟

Can an open Arabic model run a clinic's WhatsApp front desk, offline?

2,016 محادثة كاملة باللهجة الخليجية · 4 نماذج · عيادة محاكاة تردّ على كل أداة



محمود دغيم

github.com/mhdghaim-cell/arabic-llm-bench

ليس سؤالًا واحدًا. محادثة كاملة.

المهمة

يحجز ويلغي ويغيّر المواعيد ويحوّل الطوارئ لموظف، في عيادة أسنان محاكاة في دبي: أيام مسكّرة، تقويم يتعطّل، مواعيد قديمة.

المرضى

42 مريضًا باللهجة الخليجية، منهم من يكتب Arabizi، ومنهم من يغيّر رأيه في منتصف المحادثة. كل حالة 3 مرات.

النماذج

`Jais 3 (3.7B, 7B) · Qwen3 (4B, 8B)`

التشغيل

`RTX 4090 · Q4 · llama.cpp`، ولابتوب 2020 للسرعة

المعيار

مسجّل في GitHub قبل أي تشغيل.

كم محادثة انتهت صحيحة من أولها لآخرها؟



Jais 3 · 3.7B تفوّق على Qwen3 الذي يبلغ ضعف حجمه.

هل وصلت الحالات الطارئة لموظف؟

75/75

مع Jais 3 بالحجمين: كل حالة طارئة وصلت لموظف في الوقت.

مريض:

«الألم ما يتحمل وما قدرت أنام، بس عادي أبي أحجز فحص الأسبوع الياي»

Qwen3 عرض عليه مواعيد ولم يحوّله لإنسان، 5 مرات.

هل يقدر يغيّر موعدًا؟

15/27

أفضل نتيجة لأي نموذج في تغيير الموعد (Jais 3 · 7B). وQwen3 بين 2 و8 من 27.

النموذج، بعد أن حجز الموعد الجديد:

«تم إلغاء موعد 11 نوفمبر.»

لم يُلغَ شيء: لم يستدعِ أداة الإلغاء.

يحجز الجديد وينسى إلغاء القديم، أو يقول «تم» من غير أن يفعل.

هل يكفي لابتوب عادي؟

~53

ثانية: متوسط انتظار المريض لكل رد، مع Jais 3 · 3.7B بالإعداد الذي ينجح.

الإعداد السريع (نحو 10 ثوانٍ) ينجح في 29% فقط. ونماذج 7B و8B لا تتسع في ذاكرته.
للمقارنة: بطاقة RTX 4090 تردّ في نحو 2 ثانية.

Speed model validated on the laptop: median error 10%.

ماذا يفعل صاحب العيادة؟

الإعداد	الحكم
`Jais 3 · 3.7B / 7B` حجز واستفسار وتحويل طوارئ، مع تقويم في التعليمات	■ بإشراف بشري
تغيير المواعيد من غير موظف كل النماذج المختبرة	■ لا يُنشر
`Qwen3 · 4B / 8B` دون المعيار، وفاتته حالات طارئة	■ لا يُنشر
أي نموذج على لابتوب 2020 (8 GB) بطيء جدًا لواتساب	■ لا يُنشر

تقويم 14 يومًا مكتوب في التعليمات نفع مثل أداة تاريخ مبرمجة. الحل الرخيص يكفي.

لماذا تثق بالأرقام؟

موظف مثالي نجح 100%، و**تسعة موظفين سيئين عمدًا** التقطهم المصحِّح كلهم.

تدقيق بشري أعمى لـ30 محادثة: اتفاق 30/30.

ننشر ما فشل أيضًا: فرضية لم تثبت، وأخرى تحققت لـ7B فقط.

كل المحادثات والكود والبروتوكول منشورة على GitHub:

mhdghaim-cell/arabic-llm-bench

Independent work. No funding from any model lab.

مقياس
MIQYAS